

# Intelligence artificielle Support vector machines

## NXV

Mastère Data Scientist

**Antoine Vacavant** 

antoine.vacavant@ynov.com antoine.vacavant@nxv.fr

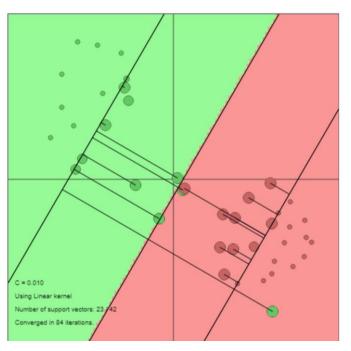
#### Plan

- 1. Principe
  - Cas linéaire
  - Première formulation
  - Cas linéairement non-séparable
- 2. Méthodes de résolution
  - Primal et dual
  - Cas non linéaire
- 3. Bilan

## Principe

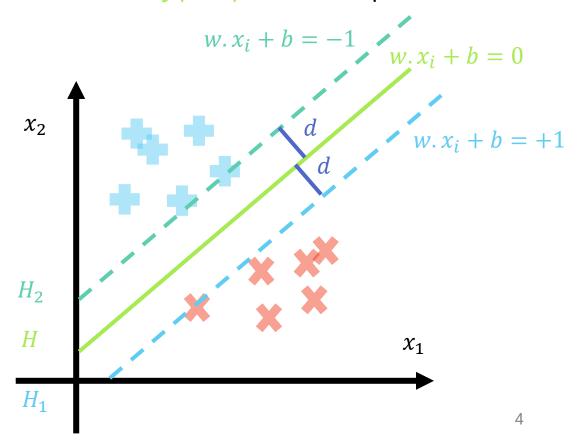
- Machines à vecteurs de support
- Calculer une fonction séparatrice des données
- En utilisant certaines d'entre elles comme support
- Inclut une marge d'erreur

- Deux approches
  - Linéaire
  - Non-linéaire



### Cas linéaire

- Dans un cadre 2-classes
- On cherche à déterminer l'hyperplan tel que
  - $-w.x_i + b \ge +1$ lorsque  $y_i = +1$
  - $-w.x_i + b \le -1$ lorsque  $y_i = -1$
- La marge : d



#### Cas linéaire

• La distance d s'exprime de la manière suivante :

$$d_i = \frac{y_i(w.x_i + b)}{\|w\|}$$

- Notre objectif : maximiser la marge  $2d_i$
- Plus simplement, on cherche à maximiser  $\frac{1}{2} ||w||^2$
- Forme quadratique
- Résolution plus simple par une approche lagrangienne

#### Cas linéaire

- On ne souhaite pas de points entre  $H_1$  et  $H_2$ 
  - $-w.x_i + b \ge +1$  lorsque  $y_i = +1$
  - $-w.x_i + b \le -1$  lorsque  $y_i = -1$
- Combinés ensemble :

$$y_i(w.x_i + b) \ge 1$$

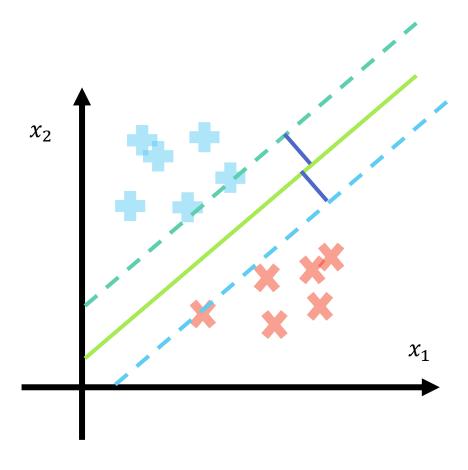
#### Première formulation

On cherche à résoudre le problème suivant :

$$\min_{\substack{w,b \ v,b}} \frac{1}{2} ||w||^2$$
tel que  $y_i(w, x_i + b) > 1 \quad \forall i = 1, ..., n$ 

## Première formulation

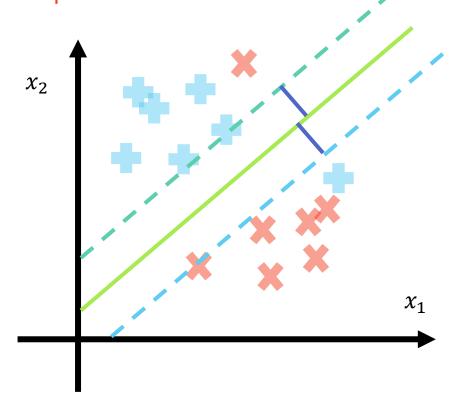
Problème de cette formulation ?



### Première formulation

Problème de cette formulation ?

Elle n'accepte pas d'outliers!



## Cas linéairement non-séparable

On cherche à résoudre le problème suivant :

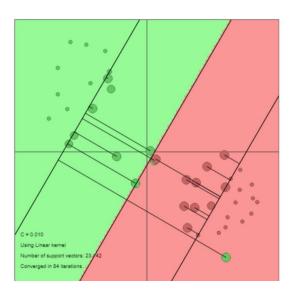
$$\min_{w,b} \frac{1}{2} ||w||^2 + \frac{C}{n} \sum_{i=1}^{n} \xi_i$$
tel que  $y_i(w, x_i + b) > 1 - \xi_i \quad \forall i = 1, ..., n$ 

$$\xi_i \ge 0$$

- $-\xi_i \geq 0$ : échantillon mal classifié
- $-\xi_i = 0$ : échantillon bien classifié
- C grand: pas d'erreur dans le calcul de la marge

## Retour sur SVMjs

- Sur ce site
  - → <a href="https://cs.stanford.edu/~karpathy/svmjs/demo/">https://cs.stanford.edu/~karpathy/svmjs/demo/</a>
- Passer en mode linéaire
- Etudier l'influence du paramètre C



- Méthodes d'optimisation
- Descente de gradient stochastique
- On peut également reformuler le calcul de w :

$$w = \sum_{i=1}^{n} \alpha_i y_i x_i$$

Où  $\alpha_i \in \mathbb{R}$ 

- Méthodes d'optimisation
- Descente de gradient stochastique
- On peut également reformuler le calcul de w :

$$w = \sum_{i=1}^{n} \alpha_i y_i x_i$$

Où  $\alpha_i \in \mathbb{R}$ 

La solution est combinaison linéaire des données

- Changement de variable de w, b à  $\alpha$
- Calcul original : primal
- Nouvelle version : dual

- Changement de variable de w, b à  $\alpha$
- Calcul original : primal
- Nouvelle version : dual
- Le problème devient alors :

$$\max_{\alpha_i \ge 0} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i x_j)$$

$$\text{tel que } 0 \le \alpha_i \le C$$

$$\sum_i \alpha_i y_i = 0$$

- Changement de variable de w, b à  $\alpha$
- Calcul original : primal
- Nouvelle version : dual
- Le problème devient alors :

$$\max_{\alpha_i \ge 0} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i x_j)$$
tel que  $0 \le \alpha_i \le C$ 

$$\sum_i \alpha_i y_i = 0$$

### Interlude

• Le calcul  $x_i$ .  $x_j$  représente l'« éloignement » des données  $x_i$  et  $x_j$ 

#### Interlude

- Le calcul  $x_i$ .  $x_j$  représente l'« éloignement » des données  $x_i$  et  $x_j$
- Si  $x_i$   $x_j = 1$  les vecteurs sont colinéaires
  - Donc complètement similaires
- Si  $x_i$   $x_j = 0$  les vecteurs sont perpendiculaires
  - Donc complètement différents

#### Interlude

- Le calcul  $x_i$ .  $x_j$  représente l'« éloignement » des données  $x_i$  et  $x_j$
- Si  $x_i$   $x_j = 1$  les vecteurs sont colinéaires
  - Donc complètement similaires
- Si  $x_i \cdot x_j = 0$  les vecteurs sont perpendiculaires
  - Donc complètement différents

Comment améliorer cette mesure de dissimilarité?

## Augmentation de dimension

Supposons une feature map suivante :

$$\phi(x): x \to \phi(x)$$
$$\mathbb{R}^d \to \mathbb{R}^D$$

- Permet d'augmenter la représentation des données
- On pourrait être tenté de calculer  $\phi(x_i)$ .  $\phi(x_j)$
- Mais calcul complexe... voire impossible numériquement

## Augmentation de dimension

- A la place, on utilise des noyaux de la forme  $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$
- Inutile de calculer  $\phi$  directement
- Le noyau devient une mesure de dissimilarité
- Exemples de noyaux pour un SVM non-linéaire
  - Polynomial:  $K(x_i, x_j) = (x_i, x_j + 1)^p$
  - RBF (radial basis function):  $K(x_i, x_j) = \exp\left(\frac{\|x_i x_j\|^2}{2\sigma^2}\right)$
  - Sigmoide :  $K(x_i, x_j) = \tanh(\kappa x_i, x_j \delta)$

#### Bilan

- Le SVM permet une classification efficace
- Surtout dans le cadre de 2 classes
- Possibilité d'une approche multi-classes
- Avec moins de paramètres qu'un réseau de neurones artificiels standard

 Mais nécessite généralement l'extraction de caractéristiques au préalable (ex. ondelettes)